


<Fic_Dev/>

Pipeline de Recomendação e Dashboard de Conteúdos Educacionais

Kevin da Silva Medeiros
Vinycius Yuji Mogami
Victor Griggi Moreira Regis da Silva

Fundamentos de Dados para IA – Prof. Elmo de Faria e Prof. Josiel Figueiredo
Pitch Técnico – Desafio 01 – Turma Noturno
13 de setembro de 2026



<Fic_Dev/> Nossa equipe



**Kevin da Silva
Medeiros**



**Vinycius Yuji
Mogami**



**Victor Griggi M.
Regis da Silva**

Sobre o sistema

O sistema nasceu para atender uma plataforma institucional com cursos, vídeos, artigos, podcasts e outros materiais distribuídos em arquivos de diferentes formatos. A instituição deseja organizar esses dados, produzir recomendações e acompanhar os principais resultados em um dashboard.

01

Entrada

Catálogo em CSV; interações e comentários em JSON

02

Processamento

Validação, tratamento, PostgreSQL, MongoDB e embeddings

03

Indicadores

Métricas e KPIs em views; dashboard no Apache Superset

04

Recomendação

Busca semântica e pontuação por usuário (Ivis, Icur, Iconc)


O que entregamos

- Um comando, tudo em Docker: **docker compose run --rm app** executa as 7 etapas do pipeline em ~10 s e pode rodar quantas vezes for preciso sem duplicar nada.
- **14 requisitos funcionais atendidos**, 17 testes automatizados, 3 bancos (PostgreSQL, MongoDB, pgvector) e 8 views alimentando o Superset.
- **3.000 registros → 2.871 válidos e 129 rejeitados com motivo**; 1.000 embeddings; 1.200 recomendações; 4 KPIs e 1 dashboard com 2 perguntas de negócio respondidas.

```
pipeline | [recomendacao] inicio
recomendacao | [RF10] usuários=150 com recomendação=120 recom
recomendacao | [RF10] usuário=1 pos=1 conteúdo=656 pontuação=
recomendacao | [RF10] usuário=1 pos=2 conteúdo=236 pontuação=5
recomendacao | [RF10] usuário=1 pos=3 conteúdo=731 pontuação=53
recomendacao | [RF11] 1200 recomendações persistidas
pipeline | [recomendacao] fim em 0.247s
pipeline | [metricas] inicio
metricas | [RF12] M1 volume: {'usuarios': 150, 'usuarios_ativos': 150
metricas | [RF12] KPI1 taxa de conclusão: {'DevOps & Cloud': 30.0, 'P
metricas | [RF12] KPI2 avaliação média: {'Engenharia de Dados': 4.72,
metricas | [RF12] KPI3 retenção mensal: {'2026-01': 53.1, '2026-02':
metricas | [RF12] KPI4 recomendação: {'estavel': 1010, 'positivo': 19
pipeline | [metricas] fim em 0.017s
pipeline | resumo gravado em dados/processados/resumo_ingestao.json
pipeline | Término do processamento em 10.386s
```

Arquitetura e requisitos funcionais

<Fic_Dev/>



Docker Compose: postgres (pgvector) · mongo · superset · app — um comando reproduz tudo: `docker compose up -d && docker compose run --rm app`

Ingestão e armazenamento

<Fic_Dev/>

3.000

registros lidos · 3 fontes

2.871

válidos · carregados

129

rejeitados · cada um com motivo

Validação em duas camadas (RF03)

- **Campo a campo:** obrigatórios, ids inteiros, datas, domínios (tipo, nível, interação), intervalos (nota 1–5, percentual 0–100), duplicidade
- **Cruzada entre fontes:** interação ou comentário **anterior à publicação do conteúdo** → 77 + 52 rejeitados; data futura; conclusão com < 100 %; avaliação sem nota
- Campo a campo os dados são limpos — só a regra cruzada rejeita. Sem ela, o resumo seria 3000/3000

Tratamento (RF04)

- Espaços colapsados; tipo, nível e categoria em forma canônica (" video " → Vídeo)
- Datas em ISO; inteiros estritos ("7.9" é inválido, não 7); tags em minúsculas
- Brutos intocados em dados/brutos/ ; tratados em dados/processados/
- Rejeitados salvos com o registro original em rejeitados.json

PostgreSQL (RF06)

6 tabelas com PK, FK, CHECK de domínio e UNIQUE ; carga em **uma transação**; pgvector no mesmo servidor

MongoDB (RF07)

948 comentários com tags e categoria desnormalizada; índices; consultas por conteúdo, tag, nota e agregação por categoria

Reproduzível

Rodar 5× dá o mesmo estado: upsert + **reconciliação** do que deixou de ser válido · 17 testes com registros sujos · tudo em Docker

Resumo da ingestão em JSON (RF05) · log com motivo de cada rejeição e tempo por etapa (RF14)

Busca vetorial e recomendação

<Fic_Dev/>

Embeddings (RF08)

- **paraphrase-multilingual-MiniLM-L12-v2** · 384 dimensões · CPU
- Texto = título + descrição; 1.000 vetores em ~20 s; não regeira os existentes
- Armazenados no **pgvector** com índice HNSW por cosseno

Busca semântica (RF09)

"Como proteger dados pessoais e atender à LGPD?"

1. Papo de Dados Ep. 39: Adequação à LGPD e Proteção de Dados Pessoais · **0,67**
2. Deep Dive Ep. 32: Casos de Sucesso em Adequação à LGPD · **0,60**
3. Papo de Dados Ep. 108: Prevenção contra Vazamentos e Segurança em APIs · **0,56**

$$\text{Pontuação} = ((I_{vis} + I_{cur}) / 2) \times 100 \times I_{conc}$$

Ivis

tempo consumido na categoria do candidato ÷ tempo total

Icur

curtidas e notas ≥ 4 na categoria ÷ total de curtidas e notas ≥ 4

Iconc

0 se o usuário já concluiu o conteúdo; 1 caso contrário

Decisão justificada

Testamos **Ivis por similaridade vetorial**: as descrições seguem o mesmo molde e o cosseno ficou entre **0,38 e 0,85** — 1.497 de 1.500 recomendações "positivas". Escolhemos a **proporção por categoria** (também prevista no RF10); o pgvector ficou no desempate e na busca.

1.200

recomendações · top 10

120

de 150 usuários · 80 %

190


positivas (≥ 70)

1.010

estáveis (40–70) · negativas descartadas

Dashboard e principais descobertas

<Fic_Dev/>



Segurança & Governança: gostam, mas não terminam

2ª melhor avaliação (**4,67**) e a **pior taxa de conclusão (11,4 %)** — problema de formato ou sequência, não de qualidade. Candidata a revisão.

Crescimento com rotatividade

Retenção mensal entre **48 % e 61 %**. Maio tem o pico de usuários ativos (93) com retenção de 51,6 %: entram novos, mas metade não volta no mês seguinte.

Cold start na recomendação

Cobertura de **80 %**: 30 usuários não têm histórico suficiente para pontuar. Próximo passo: recomendação por popularidade para esses.

Dificuldades, limitações e uso da IA

<Fic_Dev/>

Dificuldades

- Enunciado com `40 > Pontuação < 70`: interpretamos como `40 < x < 70` e registramos
- Dados sintéticos com interações **antes da publicação** do conteúdo — só apareceu com validação cruzada
- Descrições homogêneas: similaridade vetorial espremida, tudo virava "positivo"
- `conclusões ÷ inícios` passava de 100 %: taxa refeita por par usuário/conteúdo
- MongoDB 8.0 não sobe no kernel do Docker Desktop atual → 8.2

Limitações

- **Conversão de recomendações** não é mensurável: todas as interações são anteriores à primeira execução
- **Icur** usa só as interações; avaliações dos comentários (MongoDB) ficam fora do índice
- Conteúdo visualizado e não concluído continua elegível — o enunciado só remove concluídos
- Filtros do dashboard não alcançam a série mensal (view agregada por mês)
- Recomendação é um snapshot por execução; o histórico fica em `execucao_pipeline`

Uso de IA (Claude Code)

- **Para quê:** explicar erros, sugerir SQL e consultas Mongo, revisar código, sugerir métricas, melhorar a documentação
- **Erros que ela cometeu:** contagem de "corrigidos" com bug de tipo; persistência que dizia "gravado" sem gravar; fórmulas que davam resultado sem sentido
- **Como tratamos:** nada entrou sem rodar e conferir no banco; os erros foram identificados e corrigidos pela equipe
- Registro completo em `documentacao/uso_da_ia.md`

<Fic_Dev/>

Fundamentos de Dados para IA – Prof. Elmo de Faria e
Prof. Josiel Figueiredo
Pitch Técnico – Desafio 01 – Turma Noturno
13 de setembro de 2026

OBRIGADO!



Kevin da Silva Medeiros
KevinSMedeiros



Vinycius Yuji Mogami
vinyuji



**Victor
Griggi**
vctorgriggi