


Modelo de dados

Desafio Prático 1 — Pipeline de Recomendação e Dashboard de Conteúdos Educacionais · Vinycius Yuji Mogami, Victor Griggi Moreira Regis da Silva, Kevin da Silva Medeiros

1. Modelo conceitual


A plataforma tem **conteúdos** educacionais organizados em **categorias**. **Usuários** realizam **interações** com os conteúdos (visualização, início, conclusão, curtida, avaliação, compartilhamento) e escrevem **comentários** com avaliação e tags. A partir do histórico, o sistema gera **recomendações** de conteúdos para cada usuário. Cada conteúdo tem uma representação vetorial (**embedding**) usada na busca semântica.



Não existe fonte de usuários: a entidade **Usuário** é derivada dos identificadores encontrados em interações e comentários. **Comentário** é armazenado no MongoDB (semiestruturado); as demais entidades no PostgreSQL.

2. Modelo lógico — PostgreSQL

Script: `sql/criar_banco.sql`. Chaves primárias, estrangeiras, restrições de domínio (`CHECK`) e unicidade para impedir duplicidades. Extensão `vector` (`pgvector`) para os embeddings.



Restrições de integridade

Tabela	Restrição	Finalidade
categoria	UNIQUE (nome)	uma categoria por nome canônico
conteudo	CHECK tipo, CHECK nivel, CHECK carga_horaria_min >= 0, FK categoria	domínio dos valores categóricos (RF03/RF04)
interacao	UNIQUE (usuario_id, conteudo_id, tipo_interacao, data_hora); CHECK em tipo, tempo, percentual e avaliação; FKs	sem interações duplicadas; valores dentro dos intervalos
conteudo_embedding	PK em conteudo_id; índice HNSW por cosseno	um embedding por conteúdo (RF08); busca vetorial eficiente (RF09)

recomendacao	UNIQUE (usuario_id, conteudo_id, gerado_em); CHECK pontuação 0–100, posição > 0, classificação	RF10/RF11
--------------	--	-----------

Índices: interacao(usuario_id), interacao(conteudo_id), interacao(data_hora),
recomendacao(usuario_id), conteudo_embedding USING hnsw (embedding vector_cosine_ops).

Views para métricas e KPIs (RF12)

View	Natureza	Conteúdo
vw_interacoes	fato	interações com título, tipo, nível, categoria e mês — base dos filtros do dashboard
vw_metricas_gerais	métrica	usuários, ativos, conteúdos, interações, tempo médio, recomendações, cobertura, embeddings
vw_uso_mensal	métrica	interações, visualizações, usuários ativos e tempo por mês x categoria x tipo
vw_conteudos_populares	métrica	visualizações, usuários, tempo médio e avaliação por conteúdo
vw_kpi_taxa_conclusao	KPI	consumos, conclusões e taxa por categoria x tipo x nível
vw_kpi_qualidade	KPI	avaliações, média e % positivas por categoria x tipo x nível
vw_kpi_retencao_mensal	KPI	usuários ativos, interações por usuário, retidos e retenção % por mês
vw_kpi_recomendacao	KPI	recomendações, usuários, pontuação média e cobertura por classificação x categoria x tipo

3. Modelo lógico — MongoDB

Banco `desafio`, coleção `comentarios`. Um documento por comentário/avaliação, com os campos originais e três atributos do conteúdo copiados do catálogo (desnormalização), o que permite agregar por categoria sem consultar o PostgreSQL.

Campo	Tipo	Origem
<code>usuario_id</code>	int	<code>comentarios.json</code>
<code>conteudo_id</code>	int	<code>comentarios.json</code> — deve existir no catálogo válido
<code>avaliacao</code>	int 1–5	<code>comentarios.json</code>
<code>comentario</code>	string	<code>comentarios.json</code>
<code>tags</code>	array de string (minúsculas)	<code>comentarios.json</code>
<code>data</code>	string ISO (YYYY-MM-DD)	<code>comentarios.json</code> — não anterior à publicação
<code>categoria</code> , <code>titulo</code> , <code>tipo</code>	string	catálogo processado (desnormalizado)
<code>carga</code>	string ISO datetime	identificador da carga; documentos de cargas anteriores são removidos

Índices: único em (`usuario_id`, `conteudo_id`, `data`, `comentario`); simples em `conteudo_id`, `tags`, `avaliacao` e `categoria`.

```
{ "usuario_id": 137, "conteudo_id": 587, "avaliacao": 5,
  "comentario": "Conteúdo introdutório, claro e objetivo.",
  "tags": ["anonimizacao", "lgpd", "essencial"], "data": "2026-03-02",
  "categoria": "Segurança & Governança", "titulo": "...", "tipo": "Artigo",
  "carga": "2026-09-12T22:53:18" }
```

4. Decisões de modelagem

- **Categoria como entidade própria**, e não coluna texto em conteúdo: garante um nome canônico (a ingestão unifica variações de caixa e espaço) e simplifica filtros e agregações.
- **Usuário sem atributos**: não há fonte de usuários; a tabela existe para integridade referencial e para contagens.
- **Embedding em tabela separada** com o nome do modelo: permite trocar o modelo sem alterar `conteudo` e evita regerar vetores existentes (RF08).
- **Recomendação como snapshot**: cada execução substitui o conjunto anterior; o histórico de execuções fica em `execucao_pipeline`.
- **Comentários no MongoDB**: texto livre e array de tags de tamanho variável são o dado semiestruturado do desafio; no relacional exigiriam tabela auxiliar para tags.